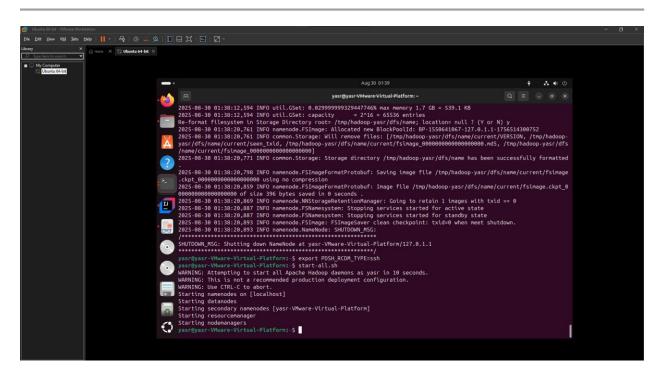
Rapport du Projet WordCount avec Hadoop

1. Objectif du Projet

L'objectif du projet est de développer une application Java utilisant **Hadoop MapReduce** pour compter le nombre d'occurrences de chaque mot dans un fichier texte. Le projet est réalisé avec **Maven** pour la gestion des dépendances et s'exécute en **mode Hadoop mono-nœud**.



2. Pré-requis

Avant de commencer, les éléments suivants doivent être installés et configurés :

- Java JDK 8
 - Vérification:
- java -version
- → doit afficher 1.8
 - Maven

Vérification:

- mvn -v
- Hadoop en mono-nœud

Installation nécessaire pour pouvoir exécuter la commande hadoop jar.

• IDE recommandé: Eclipse

3. Création du Projet Maven

1. Dans Eclipse:

o File → New → Maven Project

o Cocher Create a simple project → Next

o Paramètres du projet :

• **Group Id** : org.codewithjun

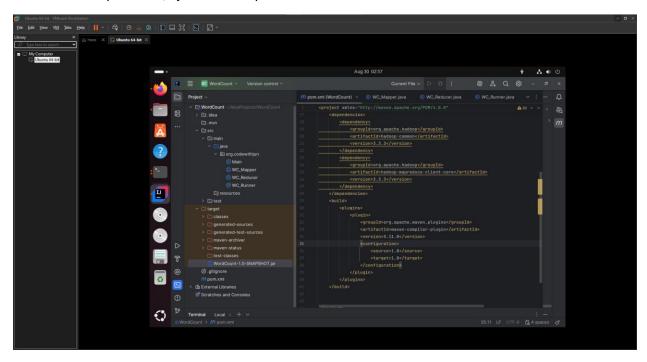
Artifact Id : wordcount

Packaging: jar

o Finish

4. Gestion des Dépendances Hadoop

Dans le fichier pom.xml, ajouter les dépendances suivantes :



<dependencies>

<dependency>

<groupId>org.apache.hadoop</groupId>

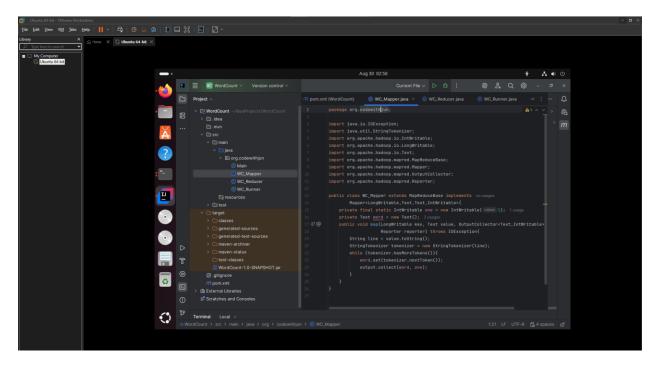
<artifactId>hadoop-common</artifactId>

```
<version>3.3.3</version>
</dependency>
<dependency>
 <groupId>org.apache.hadoop</groupId>
 <artifactId>hadoop-mapreduce-client-core</artifactId>
 <version>3.3.3</version>
</dependency>
</dependencies>
<build>
<plugins>
 <plugin>
  <groupId>org.apache.maven.plugins</groupId>
  <artifactId>maven-compiler-plugin</artifactId>
  <version>3.11.0</version>
  <configuration>
   <source>1.8</source>
   <target>1.8</target>
  </configuration>
 </plugin>
</plugins>
</build>
Sauvegarder le fichier pour que Maven télécharge les dépendances.
```

5. Création des Classes Java

Package: org.codewithjun

5.1 WC_Mapper.java



package org.codewithjun;

```
import java.io.IOException;
```

import java.util.StringTokenizer;

import org.apache.hadoop.io.IntWritable;

import org.apache.hadoop.io.LongWritable;

import org.apache.hadoop.io.Text;

import org.apache.hadoop.mapred.MapReduceBase;

import org.apache.hadoop.mapred.Mapper;

import org.apache.hadoop.mapred.OutputCollector;

import org.apache.hadoop.mapred.Reporter;

public class WC_Mapper extends MapReduceBase implements

Mapper<LongWritable,Text,Text,IntWritable>{

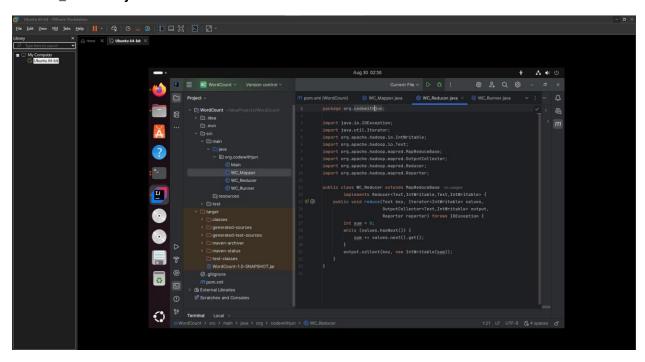
private final static IntWritable one = new IntWritable(1);

private Text word = new Text();

public void map(LongWritable key, Text value, OutputCollector<Text,IntWritable> output,

```
Reporter reporter) throws IOException{
String line = value.toString();
StringTokenizer tokenizer = new StringTokenizer(line);
while (tokenizer.hasMoreTokens()){
   word.set(tokenizer.nextToken());
   output.collect(word, one);
}
}
```

5.2 WC_Reducer.java



package org.codewithjun;

import java.io.IOException;

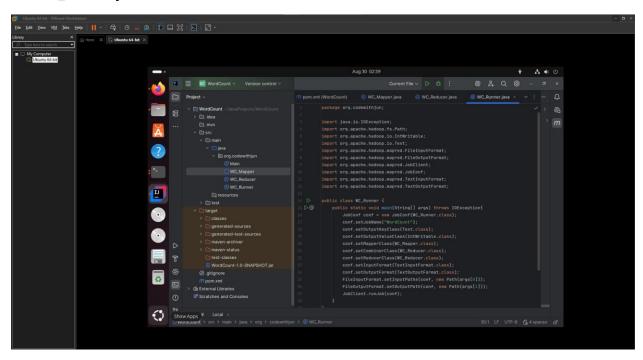
import java.util.Iterator;

import org.apache.hadoop.io.IntWritable;

import org.apache.hadoop.io.Text;

import org.apache.hadoop.mapred.MapReduceBase;

5.3 WC_Runner.java



```
package org.codewithjun;
import java.io.IOException;
import org.apache.hadoop.fs.Path;
import org.apache.hadoop.io.IntWritable;
import org.apache.hadoop.io.Text;
import org.apache.hadoop.mapred.FileInputFormat;
import org.apache.hadoop.mapred.FileOutputFormat;
import org.apache.hadoop.mapred.JobClient;
import org.apache.hadoop.mapred.JobConf;
import org.apache.hadoop.mapred.TextInputFormat;
import org.apache.hadoop.mapred.TextOutputFormat;
public class WC_Runner {
  public static void main(String[] args) throws IOException{
   JobConf conf = new JobConf(WC_Runner.class);
   conf.setJobName("WordCount");
   conf.setOutputKeyClass(Text.class);
   conf.setOutputValueClass(IntWritable.class);
   conf.setMapperClass(WC_Mapper.class);
   conf.setCombinerClass(WC_Reducer.class);
   conf.setReducerClass(WC_Reducer.class);
   conf.setInputFormat(TextInputFormat.class);
   conf.setOutputFormat(TextOutputFormat.class);
   FileInputFormat.setInputPaths(conf, new Path(args[0]));
   FileOutputFormat.setOutputPath(conf, new Path(args[1]));
   JobClient.runJob(conf);
 }
}
```

6. Préparation du Fichier d'Entrée

```
yasr@yasr-VMware-Virtual-Platform:-/Desktop$ hadoop fs -mkdir /input
yasr@yasr-VMware-Virtual-Platform:-/Desktop$ hadoop fs -put input.txt /input
```

- Créer un dossier input dans le projet
- Ajouter un fichier input.txt contenant quelques lignes de texte

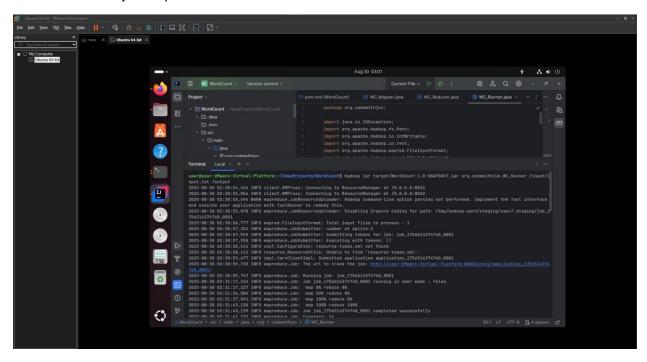
7. Compilation et Packaging

- Dans Eclipse: Run As → Maven build... → Goals: clean package → Run
- Ou en terminal : mvn clean package

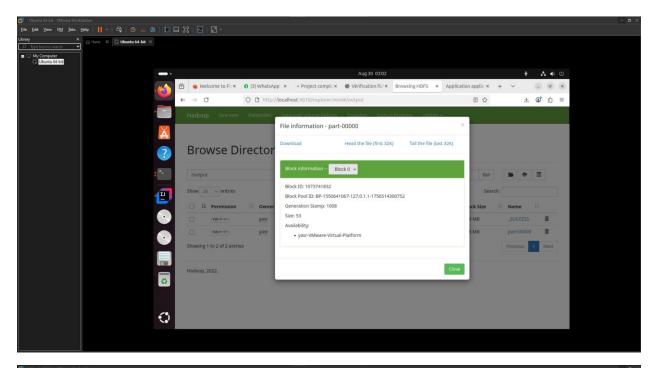
Un fichier JAR sera généré dans le dossier target.

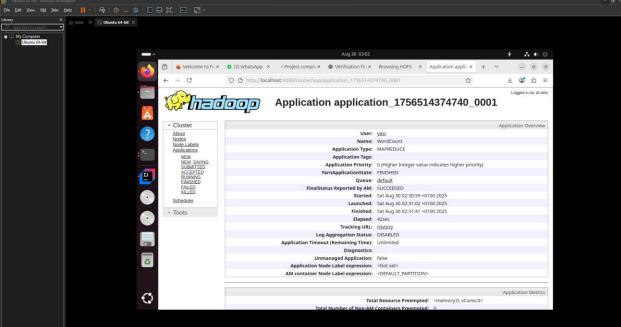
8. Exécution du Job WordCount avec Hadoop

1. Lancer le job MapReduce :



hadoop jar target/WordCount-1.0-SNAPSHOT.jar org.codewithjun.WC_Runner /input/input.txt /output





Realiser Par:

Yassir El ghrissi